

Dicionário de Variáveis — PRF Dados Abertos

Datasets consolidados do pacote `tidypfr`

2026-05-03

Sumário

1	Introdução	1
1.1	Convenções	1
1.2	Estrutura de arquivos gerados	2
2	Dataset: Acidentes por Pessoa (acidentes)	2
3	Dataset: Acidentes por Ocorrência (datatran)	4
4	Dataset: Infrações (infracoes)	5
5	Padronização aplicada em todos os datasets	6
5.1	Conversão de NA	6
5.2	Normalização de <code>uso_solo</code>	6
5.3	Normalização de <code>sexo</code> (acidentes)	6
5.4	Parsing de datas	6
5.5	Compressão e formato Parquet	7
6	Fontes e referências	7

1 Introdução

Este dicionário documenta o schema unificado dos três datasets consolidados pelo pacote **`tidypfr`**, derivados dos dados abertos da Polícia Rodoviária Federal (PRF). Os arquivos Parquet resultantes cobrem o período 2007–2026 e são consumidos via download sob demanda pelas funções do pacote.

1.1 Convenções

- **Tipo:** tipo R após leitura e conversão — `chr` (character), `int` (integer), `dbl` (double), `Date`.
- **Cobertura:** indica os anos em que a coluna está disponível. Colunas ausentes em determinado período são armazenadas como NA.

- **NA aplicados:** além dos NA nativos do R, os seguintes valores nos CSVs originais são convertidos para NA real: "", "NA", "Ignorado", "Não informado", "Não Informado", "NÃO INFORMADO", "-", "N/A". Para a coluna *idade*, o valor -1 também é convertido para NA.

1.2 Estrutura de arquivos gerados

```
dados/consolidados/
  acidentes/      acidentes_2007.parquet ... acidentes_2026.parquet
  datatran/       datatran_2007.parquet ... datatran_2026.parquet
  infracoes/     infracoes_2019.parquet ... infracoes_2026.parquet
  catalogo.json
```

2 Dataset: Acidentes por Pessoa (acidentes)

Função no pacote: `acidentes_obter(year, ...)` **Granularidade:** Uma linha por **pessoa** envolvida em um acidente **Cobertura temporal:** 2007–2026 **Fontes CSV:**

- 2007–2015: `acidentes{ano}.csv` — separador vírgula, encoding Latin-1
- 2016: `acidentes2016_atual.csv` — separador ponto e vírgula
- 2017–2026: `acidentes{ano}_todas_causas_tipos.csv` — separador ponto e vírgula

Nota de schema: Os dados até 2016 foram coletados pelo sistema BR-Brasil; a partir de 2017, pelo sistema BAT. As colunas presentes em apenas uma das eras são preenchidas com NA na era em que estão ausentes.

Tabela 1: Schema unificado — Acidentes por pessoa (39 colunas)

Coluna	Tipo	Cobertura	Descricao
<code>id</code>	chr	2007–2026	Identificador único do acidente
<code>pesid</code>	chr	2007–2026	Identificador único da pessoa envolvida
<code>data_inversa</code>	Date	2007–2026	Data do acidente (todos os formatos originais normalizados para Date)
<code>dia_semana</code>	chr	2007–2026	Dia da semana por extenso, minúsculas
<code>horario</code>	chr	2007–2026	Hora do acidente no formato HH:MM:SS
<code>uf</code>	chr	2007–2026	Sigla da UF, 2 letras maiúsculas
<code>br</code>	int	2007–2026	Número da rodovia federal (BR)
<code>km</code>	dbl	2007–2026	Quilômetro da rodovia; vírgula decimal convertida para ponto
<code>municipio</code>	chr	2007–2026	Nome do município
<code>causa_principal</code>	chr	2017–2026	Causa classificada como principal; NA em dados pré-2017 (coluna inexistente)
<code>causa_acidente</code>	chr	2007–2026	Causa do acidente (texto normalizado)
<code>ordem_tipo_acidente</code>	int	2017–2026	Ordem do tipo de acidente na ocorrência; NA pré-2017
<code>tipo_acidente</code>	chr	2007–2026	Tipo de acidente (colisão, atropelamento, capotamento, etc.)

Tabela 1: Schema unificado — Acidentes por pessoa (39 colunas) (*continued*)

Coluna	Tipo	Cobertura	Descricao
<code>classificacao_acidente</code>	chr	2007–2026	Classificação da gravidade: Sem Vítimas / Com Vítimas Feridas / Com Vítimas Fatais
<code>fase_dia</code>	chr	2007–2026	Fase do dia: Pleno Dia, Amanhecer, Anoitecer, Plena Noite
<code>sentido_via</code>	chr	2007–2026	Sentido do tráfego: Crescente, Decrescente
<code>condicao_meteorologica</code>	chr	2007–2026	Condição meteorológica no momento do acidente
<code>tipo_pista</code>	chr	2007–2026	Tipo de pista: Dupla, Simples, Múltipla
<code>tracado_via</code>	chr	2007–2026	Traçado da via: Reta, Curva, Interseção, etc.
<code>uso_solo</code>	chr	2007–2026	Tipo de uso do solo. Normalizado: 'Sim'→'Urbano', 'Não'→'Rural' para 2017+
<code>id_veiculo</code>	chr	2007–2026	Identificador do veículo envolvido
<code>tipo_veiculo</code>	chr	2007–2026	Tipo do veículo: Automóvel, Caminhão, Motocicleta, etc.
<code>marca</code>	chr	2007–2026	Marca do veículo
<code>ano_fabricacao_veiculo</code>	int	2007–2026	Ano de fabricação do veículo
<code>tipo_envolvido</code>	chr	2007–2026	Tipo de envolvimento: Condutor, Passageiro, Pedestre, etc.
<code>estado_fisico</code>	chr	2007–2026	Estado físico da pessoa: Ileso, Ferido Leve, Ferido Grave, Morto, Ignorado
<code>idade</code>	int	2007–2026	Idade da pessoa em anos. -1 convertido para NA
<code>sexo</code>	chr	2007–2026	Sexo. Normalizado: 'M'→'Masculino', 'F'→'Feminino'
<code>nacionalidade</code>	chr	2007–2016	Nacionalidade da pessoa; presente apenas em 2007–2016 (BA pós-2016 não coleta)
<code>naturalidade</code>	chr	2007–2016	Naturalidade da pessoa; presente apenas em 2007–2016
<code>ilesos</code>	int	2017–2026	Binário 0/1: indica se esta pessoa ficou ilesa; NA pré-2017
<code>feridos_leves</code>	int	2017–2026	Binário 0/1: indica se esta pessoa teve ferimento leve; NA pré-2017
<code>feridos_graves</code>	int	2017–2026	Binário 0/1: indica se esta pessoa teve ferimento grave; NA pré-2017
<code>mortos</code>	int	2017–2026	Binário 0/1: indica se esta pessoa morreu; NA pré-2017
<code>latitude</code>	dbl	2017–2026	Latitude (SIRGAS 2000 / EPSG:4674); NA pré-2017
<code>longitude</code>	dbl	2017–2026	Longitude (SIRGAS 2000 / EPSG:4674); NA pré-2017
<code>regional</code>	chr	2017–2026	Código da regional PRF; NA pré-2017
<code>delegacia</code>	chr	2017–2026	Delegacia de referência; NA pré-2017
<code>uop</code>	chr	2017–2026	Unidade operacional; NA pré-2017
<code>ano</code>	int	2007–2026	Ano derivado de year(data_inversa); sempre presente

Nota sobre contagens: As colunas `ilesos`, `feridos_leves`, `feridos_graves` e `mortos` em acidentes são **binárias** (0 ou 1) — indicam o estado físico da pessoa na linha. Para obter contagens por acidente, some sobre `id`. No dataset `datatran`, as mesmas colunas são **contagens** por ocorrência.

3 Dataset: Acidentes por Ocorrência (datatran)

Função no pacote: `datatran_obter(year, ...)` **Granularidade:** Uma linha por **ocorrência** (acidente como evento único) **Cobertura temporal:** 2007–2026 **Fonte CSV:** `datatran{ano}.csv` — separador ponto e vírgula em todos os anos

Nota de schema: Diferente de `acidentes`, este dataset agrega a ocorrência: campos de pessoa e veículo individuais são substituídos por contagens totais.

Tabela 2: Schema unificado — Acidentes por ocorrência/datatran (31 colunas)

Coluna	Tipo	Cobertura	Descricao
<code>id</code>	chr	2007–2026	Identificador único do acidente
<code>data_inversa</code>	Date	2007–2026	Data do acidente (normalizada para Date)
<code>dia_semana</code>	chr	2007–2026	Dia da semana por extenso, minúsculas
<code>horario</code>	chr	2007–2026	Hora do acidente no formato HH:MM:SS
<code>uf</code>	chr	2007–2026	Sigla da UF, 2 letras maiúsculas
<code>br</code>	int	2007–2026	Número da rodovia federal (BR)
<code>km</code>	dbl	2007–2026	Quilômetro da rodovia
<code>municipio</code>	chr	2007–2026	Nome do município
<code>causa_acidente</code>	chr	2007–2026	Causa do acidente
<code>tipo_acidente</code>	chr	2007–2026	Tipo de acidente
<code>classificacao_acidente</code>	chr	2007–2026	Gravidade: Sem Vítimas / Com Vítimas Feridas / Com Vítimas Fatais
<code>fase_dia</code>	chr	2007–2026	Fase do dia
<code>sentido_via</code>	chr	2007–2026	Sentido do tráfego: Crescente, Decrescente
<code>condicao_metereologica</code>	chr	2007–2026	Condição meteorológica
<code>tipo_pista</code>	chr	2007–2026	Tipo de pista
<code>tracado_via</code>	chr	2007–2026	Traçado da via
<code>uso_solo</code>	chr	2007–2026	Uso do solo. Normalizado: 'Sim'→'Urbano', 'Não'→'Rural' para 2017+
<code>peessoas</code>	int	2007–2026	Total de pessoas envolvidas no acidente
<code>mortos</code>	int	2007–2026	Número de mortos na ocorrência (contagem, não binário)
<code>feridos_leves</code>	int	2007–2026	Número de feridos leves (contagem)
<code>feridos_graves</code>	int	2007–2026	Número de feridos graves (contagem)
<code>ilesos</code>	int	2007–2026	Número de ilesos (contagem)
<code>ignorados</code>	int	2007–2026	Pessoas com estado físico ignorado (contagem)
<code>feridos</code>	int	2007–2026	Total de feridos (leves + graves)
<code>veiculos</code>	int	2007–2026	Total de veículos envolvidos
<code>latitude</code>	dbl	2012–2026	Latitude (SIRGAS 2000); NA para 2007–2011
<code>longitude</code>	dbl	2012–2026	Longitude (SIRGAS 2000); NA para 2007–2011
<code>regional</code>	chr	2012–2026	Código da regional PRF; NA para 2007–2011
<code>delegacia</code>	chr	2012–2026	Delegacia de referência; NA para 2007–2011
<code>uop</code>	chr	2012–2026	Unidade operacional; NA para 2007–2011
<code>ano</code>	int	2007–2026	Ano derivado de <code>year(data_inversa)</code>

4 Dataset: Infrações (infracoes)

Função no pacote: `infracoes_obter(year, ...)` **Granularidade:** Uma linha por **infração de trânsito** registrada **Cobertura temporal:** 2019–2026 (2021 ausente nos dados disponíveis) **Fontes CSV:**

- 2019–2020: `infracoes_{ano}_{MM}.csv` — separador ;, BOM UTF-8, 22 colunas
- 2022–2026: `ajustados_{ano}/infracoes{ano}_{MM}.csv` — separador ;, 25 colunas

Todos os meses são concatenados antes de escrever o Parquet anual. As 3 colunas extras de 2022+ (`tipo_veiculo`, `nom_modelo_veiculo`, `qtd_infracoes`) são NA para 2019–2020.

Tabela 3: Schema unificado — Infrações (26 colunas)

Coluna	Tipo	Cobertura	Descricao
<code>numero_auto</code>	chr	2019–2026	Número do auto de infração
<code>dat_infracao</code>	Date	2019–2026	Data da infração (parse_data_prf, formato original dd/mm/aaaa)
<code>tip_abordagem</code>	chr	2019–2026	Tipo de abordagem: Ostensiva, Eletrônica
<code>indassinou_auto</code>	chr	2019–2026	Condutor assinou o auto? S/N
<code>ind_veiculo_estrangeiro</code>	chr	2019–2026	Veículo estrangeiro? S/N
<code>ind_sentido_trafego</code>	chr	2019–2026	Sentido do tráfego no momento da infração
<code>uf_placa</code>	chr	2019–2026	UF da placa do veículo infrator
<code>uf_infracao</code>	chr	2019–2026	UF onde ocorreu a infração
<code>num_br_infracao</code>	int	2019–2026	Número da BR onde ocorreu a infração
<code>num_km_infracao</code>	dbl	2019–2026	Quilômetro da BR
<code>nom_municipio</code>	chr	2019–2026	Município da infração
<code>cod_infracao</code>	chr	2019–2026	Código do artigo do CTB infringido
<code>descricao_abreviada</code>	chr	2019–2026	Descrição abreviada da infração
<code>enquadramento</code>	chr	2019–2026	Enquadramento legal da infração
<code>data_inicio_vigencia</code>	Date	2019–2026	Data de início de vigência do artigo (parse_data_prf)
<code>data_fim_vigencia</code>	Date	2019–2026	Data de fim de vigência do artigo (parse_data_prf)
<code>med_realizada</code>	dbl	2019–2026	Medição realizada (ex.: velocidade medida em km/h)
<code>med_considerada</code>	dbl	2019–2026	Medição considerada para cálculo da penalidade
<code>exc_verificado</code>	dbl	2019–2026	Excesso verificado (medição considerada — limite legal)
<code>especie</code>	chr	2019–2026	Espécie do veículo (automóvel, moto, caminhão, etc.)
<code>nome_veiculo_marca</code>	chr	2019–2026	Marca do veículo
<code>tipo_veiculo</code>	chr	2022–2026	Tipo do veículo; NA para 2019–2020 (coluna inexistente)
<code>nom_modelo_veiculo</code>	chr	2022–2026	Modelo do veículo; NA para 2019–2020
<code>hora</code>	chr	2019–2026	Hora da infração no formato HH:MM:SS
<code>qtd_infracoes</code>	int	2022–2026	Quantidade de infrações do auto; NA para 2019–2020
<code>ano</code>	int	2019–2026	Ano derivado de year(dat_infracao)

5 Padronização aplicada em todos os datasets

5.1 Conversão de NA

Os seguintes valores nos CSVs originais são convertidos para NA real do R antes de escrever o Parquet:

Valor no CSV	Contexto
" " (vazio)	Qualquer coluna
"NA"	Qualquer coluna
"Ignorado"	Estado físico, condição meteorológica, etc.
"Não informado" / "Não Informado" / "NÃO INFORMADO"	Campos de texto
"_"	Campos numéricos e texto
"N/A"	Qualquer coluna
-1 (numérico)	Coluna <i>idade</i> (sentinela de dado ausente)

5.2 Normalização de uso_solo

A partir de 2017, o sistema BAT registra *uso_solo* como "Sim" (urbano) e "Não" (rural). O consolidador normaliza para o vocabulário histórico:

Valor original (2017+)	Valor normalizado
"Sim"	"Urbano"
"Não"	"Rural"

5.3 Normalização de sexo (acidentes)

Valor original	Valor normalizado
"M"	"Masculino"
"F"	"Feminino"

5.4 Parsing de datas

Função `parse_data_prf()` aplicada a todas as colunas de data:

```
parse_data_prf <- function(x) {  
  lubridate::parse_date_time(  
    x,  
    orders = c("Ymd", "dmY", "dmy"),  
    quiet = TRUE  
  ) |> as.Date()  
}
```

Formato original	Exemplo	Presente em
YYYY-MM-DD	2023-03-15	Acidentes 2017+, Datatran 2012–2013, 2015, 2017+
DD/MM/YYYY	15/03/2023	Acidentes 2007–2015, Datatran 2007–2011, 2014, Infrações
DD/MM/YY	15/03/16	Acidentes 2016, Datatran 2016

5.5 Compressão e formato Parquet

- **Codec:** Snappy — equilíbrio entre tamanho e velocidade de leitura
- **Compatível com:** `{arrow}` e `{duckdb}` no R
- **Tamanho esperado:** ~2–8 MB por arquivo anual dependendo do dataset e ano

6 Fontes e referências

Dicionário original	Aplica a
Dicionário de Variáveis_pessoa_2017_todas_causas_tipos.pdf	Acidentes 2017+
acidentes agrupados por pessoa (até 2016).pdf	Acidentes 2007–2016
Dicionário de Variáveis_ocorrencia_2017.pdf	Datatran 2017+
acidentes agrupados por ocorrência (até 2016).pdf	Datatran 2007–2016
dicionario-de-variaveis-infracoes.pdf	Infrações 2019+